

Архитектура AI Lab

RAG семантический поиск по корпусу + предвычисленные находки, отданные в Claude по протоколу **MCP**. **На живом пути — ноль LLM на стороне сервера.**



Claude — рассуждение и генерация (host)

получает фрагменты + таблицы → пишет ответ **с цитатами на источники** (это «augmented» в RAG)

↕ подключение инструментов по **MCP** (streamable HTTP) — без кастомной интеграции



ai-lab-mcp — слой данных · 8 инструментов · 0 LLM, 0 токенов



RAG -retrieval

`search_corpus` → векторный поиск по Chroma, возвращает релевантные фрагменты



Предвычисленные данные

`find_numeric/logic_contradictions`,
`find_open_promises` → готовые таблицы SQLite



Документы

`get_document`, `list_documents`, `corpus_stats`,
`health`

↑ читает из предвычисленных хранилищ · ↓ наполняются один раз при индексации

ИНДЕКСАЦИЯ — офлайн, один раз (здесь и только здесь работает LLM)



Корпус Avito

83 документа: стратегии + регламенты



чанкинг,
эмбединги



Chroma

векторная БД (локальная модель эмбедингов)
— источник для RAG



LLM-
детекторы



SQLite

предвычисленные расхождения, обещания,
логические сигналы

RAG, а не «память модели». Ответ обоснован фрагментами, найденными в корпусе → меньше галлюцинаций, есть цитаты.

MCP как интерфейс. Стандартный протокол: инструменты подключаются к любому MCP-хосту (Claude.ai, Avito AI) без кастомного кода.

Тяжёлое — офлайн. Детекторы и эмбединги посчитаны при индексации → живой путь мгновенный и без расхода токенов.